

# Random Forest

랜덤포레스트

배영랑 박사과정

**CMA&AI Lab**

*Color Material Application & AI Lab*

# Random Forest


랜덤 포레스트(Random Forest)는

**의사결정나무(Decision Tree)**를 무작위(Random)로 여러 개를 만들어 각각의 예측을 종합해 최종 결과를 내는 **앙상블(Ensemble)** 학습 방법.


Decision Tree(의사결정나무)는

데이터를 기준에 따라 분할해 예측을 수행하는 트리 구조의 알고리즘.

Decision Tree



Random Forest  
Decision Tree Ensemble




# Decision Tree

Decision Tree는


질문을 반복하면서, 데이터를 계속 나누는 알고리즘

| 구분  | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적  |
|-----|------|------|------|------|-----|
| A   | 5    | 1    | 10   | 8    | 15  |
| B   | 2    | 1    | 8    | 9    | 21  |
| C   | 3    | 2    | 1    | 10   | 29  |
| D   | 5    | 4    | 9    | 6    | 38  |
| E   | 4    | 4    | 5    | 7    | 52  |
| F   | 5    | 4    | 6    | 4    | 63  |
| G   | 6    | 5    | 2    | 5    | 70  |
| H   | 9    | 7    | 4    | 1    | 78  |
| I   | 7    | 7    | 3    | 2    | 91  |
| J   | 9    | 8    | 3    | 3    | 95  |
| 예측용 | 7    | 6    | 2    | 9    | ??? |




⇒ 분할 전/후 상태 비교는 어떻게?

⇒ 어떤 기준이 좋은 기준일까?



# 데이터 상태와 분할

| 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) |
|----|------|------|------|------|----|------|--------|-----------|---------------|
| A  | 5    | 1    | 10   | 8    | 15 | 55   | -40    | 1616      | 744           |
| B  | 2    | 1    | 8    | 9    | 21 |      | -34    | 1170      |               |
| C  | 3    | 2    | 1    | 10   | 29 |      | -26    | 686       |               |
| D  | 5    | 4    | 9    | 6    | 38 |      | -17    | 296       |               |
| E  | 4    | 4    | 5    | 7    | 52 |      | -3     | 10        |               |
| F  | 5    | 4    | 6    | 4    | 63 |      | 8      | 61        |               |
| G  | 6    | 5    | 2    | 5    | 70 |      | 15     | 219       |               |
| H  | 9    | 7    | 4    | 1    | 78 |      | 23     | 520       |               |
| I  | 7    | 7    | 3    | 2    | 91 |      | 36     | 1282      |               |
| J  | 9    | 8    | 3    | 3    | 95 |      | 40     | 1584      |               |



| 기준           | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE<br>가중합 |
|--------------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|------------|
| 알바시간<br>≤5.5 | F  | 5    | 4    | 6    | 4    | 63 | 79   | -16    | 269       | 147           | 0.5 | 159        |
|              | G  | 6    | 5    | 2    | 5    | 70 |      | -9     | 88        |               |     |            |
|              | H  | 9    | 7    | 4    | 1    | 78 |      | -1     | 2         |               |     |            |
|              | I  | 7    | 7    | 3    | 2    | 91 |      | 12     | 135       |               |     |            |
|              | J  | 9    | 8    | 3    | 3    | 95 |      | 16     | 243       |               |     |            |
| 알바시간<br>>5.5 | A  | 5    | 1    | 10   | 8    | 15 | 31   | -16    | 256       | 170           | 0.5 |            |
|              | B  | 2    | 1    | 8    | 9    | 21 |      | -10    | 100       |               |     |            |
|              | C  | 3    | 2    | 1    | 10   | 29 |      | -2     | 4         |               |     |            |
|              | D  | 5    | 4    | 9    | 6    | 38 |      | 7      | 49        |               |     |            |
|              | E  | 4    | 4    | 5    | 7    | 52 |      | 21     | 441       |               |     |            |

⇒ 분할 전 MSE > 분할 후 MSE  
⇒ 오차(MSE) 감소

| 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) |
|----|------|------|------|------|----|------|--------|-----------|---------------|
| A  | 5    | 1    | 10   | 8    | 15 | 55   | -40    | 1616      | 744           |
| B  | 2    | 1    | 8    | 9    | 21 |      | -34    | 1170      |               |
| C  | 3    | 2    | 1    | 10   | 29 |      | -26    | 686       |               |
| D  | 5    | 4    | 9    | 6    | 38 |      | -17    | 296       |               |
| E  | 4    | 4    | 5    | 7    | 52 |      | -3     | 10        |               |
| F  | 5    | 4    | 6    | 4    | 63 |      | 8      | 61        |               |
| G  | 6    | 5    | 2    | 5    | 70 |      | 15     | 219       |               |
| H  | 9    | 7    | 4    | 1    | 78 |      | 23     | 520       |               |
| I  | 7    | 7    | 3    | 2    | 91 |      | 36     | 1282      |               |
| J  | 9    | 8    | 3    | 3    | 95 |      | 40     | 1584      |               |


| 기준          | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE 가중합 |
|-------------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|---------|
| 알바시간 <= 5.5 | F  | 5    | 4    | 6    | 4    | 63 | 79   | -16    | 269       | 147           | 0.5 | 159     |
|             | G  | 6    | 5    | 2    | 5    | 70 |      | -9     | 88        |               |     |         |
|             | H  | 9    | 7    | 4    | 1    | 78 |      | -1     | 2         |               |     |         |
|             | I  | 7    | 7    | 3    | 2    | 91 |      | 12     | 135       |               |     |         |
|             | J  | 9    | 8    | 3    | 3    | 95 |      | 16     | 243       |               |     |         |
| 알바시간 > 5.5  | A  | 5    | 1    | 10   | 8    | 15 | 31   | -16    | 256       | 170           | 0.5 |         |
|             | B  | 2    | 1    | 8    | 9    | 21 |      | -10    | 100       |               |     |         |
|             | C  | 3    | 2    | 1    | 10   | 29 |      | -2     | 4         |               |     |         |
|             | D  | 5    | 4    | 9    | 6    | 38 |      | 7      | 49        |               |     |         |
|             | E  | 4    | 4    | 5    | 7    | 52 |      | 21     | 441       |               |     |         |

| 기준        | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE 가중합 |
|-----------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|---------|
| 집중시간 <= 6 | F  | 5    | 4    | 6    | 4    | 63 | 67   | -4     | 12        | 12            | 0.4 | 36.5    |
|           | G  | 6    | 5    | 2    | 5    | 70 |      | 4      | 12        |               |     |         |
| 집중시간 > 6  | H  | 9    | 7    | 4    | 1    | 78 | 88   | -10    | 100       | 53            | 0.6 |         |
|           | I  | 7    | 7    | 3    | 2    | 91 |      | 3      | 9         |               |     |         |
|           | J  | 9    | 8    | 3    | 3    | 95 |      | 7      | 49        |               |     |         |

| 기준          | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE 가중합 |
|-------------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|---------|
| 운동시간 <= 3.5 | H  | 9    | 7    | 4    | 1    | 78 | 78   | 0      | 0         | 0             | 0.3 | 2.4     |
| 운동시간 <= 3.5 | I  | 7    | 7    | 3    | 2    | 91 | 93   | -2     | 4         | 4             | 0.6 |         |
|             | J  | 9    | 8    | 3    | 3    | 95 |      | 2      | 4         |               |     |         |
|             |    |      |      |      |      |    |      |        |           |               |     |         |


| 기준        | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE 가중합 |  |
|-----------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|---------|--|
| 집중시간 <= 3 | A  | 5    | 1    | 10   | 8    | 15 | 22   | -7     | 44        | 33            | 0.6 | 39      |  |
|           | B  | 2    | 1    | 8    | 9    | 21 |      | -1     | 0         |               |     |         |  |
|           | C  | 3    | 2    | 1    | 10   | 29 |      | 7      | 54        |               |     |         |  |
| 집중시간 > 3  | D  | 5    | 4    | 9    | 6    | 38 | 45   | -7     | 49        | 49            | 0.4 |         |  |
|           | E  | 4    | 4    | 5    | 7    | 52 |      | 7      | 49        |               |     |         |  |

| 기준        | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE 가중합 |
|-----------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|---------|
| 공부시간 <= 4 | B  | 2    | 1    | 8    | 9    | 21 | 25   | -4     | 16        | 16            | 0.6 | 9.6     |
|           | C  | 3    | 2    | 1    | 10   | 29 |      | 4      | 16        |               |     |         |
| 공부시간 > 4  | A  | 5    | 1    | 10   | 8    | 15 | 15   | 0      | 0         | 0             | 0.3 |         |



| 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) |
|----|------|------|------|------|----|------|--------|-----------|---------------|
| A  | 5    | 1    | 10   | 8    | 15 | 55   | -40    | 1616      | 744           |
| B  | 2    | 1    | 8    | 9    | 21 |      | -34    | 1170      |               |
| C  | 3    | 2    | 1    | 10   | 29 |      | -26    | 686       |               |
| D  | 5    | 4    | 9    | 6    | 38 |      | -17    | 296       |               |
| E  | 4    | 4    | 5    | 7    | 52 |      | -3     | 10        |               |
| F  | 5    | 4    | 6    | 4    | 63 |      | 8      | 61        |               |
| G  | 6    | 5    | 2    | 5    | 70 |      | 15     | 219       |               |
| H  | 9    | 7    | 4    | 1    | 78 |      | 23     | 520       |               |
| I  | 7    | 7    | 3    | 2    | 91 |      | 36     | 1282      |               |
| J  | 9    | 8    | 3    | 3    | 95 |      | 40     | 1584      |               |

| 구분  | 공부 시간 | 집중 시간 | 운동 시간 | 알바 시간 | 성적 |
|-----|-------|-------|-------|-------|----|
| 예측용 | 7     | 6     | 2     | 9     | 45 |



| 기준         | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE 가중합 |
|------------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|---------|
| 알바시간 ≤ 5.5 | F  | 5    | 4    | 6    | 4    | 63 | 79   | -16    | 269       | 147           | 0.5 | 159     |
|            | G  | 6    | 5    | 2    | 5    | 70 |      | -9     | 88        |               |     |         |
|            | H  | 9    | 7    | 4    | 1    | 78 |      | -1     | 2         |               |     |         |
|            | I  | 7    | 7    | 3    | 2    | 91 |      | 12     | 135       |               |     |         |
|            | J  | 9    | 8    | 3    | 3    | 95 |      | 16     | 243       |               |     |         |
| 알바시간 > 5.5 | A  | 5    | 1    | 10   | 8    | 15 | 31   | -16    | 256       | 170           | 0.5 | 159     |
|            | B  | 2    | 1    | 8    | 9    | 21 |      | -10    | 100       |               |     |         |
|            | C  | 3    | 2    | 1    | 10   | 29 |      | -2     | 4         |               |     |         |
|            | D  | 5    | 4    | 9    | 6    | 38 |      | 7      | 49        |               |     |         |
|            | E  | 4    | 4    | 5    | 7    | 52 |      | 21     | 441       |               |     |         |

| 기준       | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE 가중합 |
|----------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|---------|
| 집중시간 ≤ 6 | F  | 5    | 4    | 6    | 4    | 63 | 67   | -4     | 12        | 12            | 0.4 | 36.5    |
|          | G  | 6    | 5    | 2    | 5    | 70 |      | 4      | 12        |               |     |         |
| 집중시간 > 6 | H  | 9    | 7    | 4    | 1    | 78 | 88   | -10    | 100       | 53            | 0.6 | 36.5    |
|          | I  | 7    | 7    | 3    | 2    | 91 |      | 3      | 9         |               |     |         |
|          | J  | 9    | 8    | 3    | 3    | 95 |      | 7      | 49        |               |     |         |

| 기준         | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE 가중합 |
|------------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|---------|
| 운동시간 ≤ 3.5 | H  | 9    | 7    | 4    | 1    | 78 | 78   | 0      | 0         | 0             | 0.3 | 2.4     |
|            | I  | 7    | 7    | 3    | 2    | 91 |      | -2     | 4         |               |     |         |
| 운동시간 < 3.5 | J  | 9    | 8    | 3    | 3    | 95 | 93   | 2      | 4         | 4             | 0.6 | 2.4     |


| 기준       | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE 가중합 |
|----------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|---------|
| 집중시간 ≤ 3 | A  | 5    | 1    | 10   | 8    | 15 | 22   | -7     | 44        | 33            | 0.6 | 39      |
|          | B  | 2    | 1    | 8    | 9    | 21 |      | -1     | 0         |               |     |         |
|          | C  | 3    | 2    | 1    | 10   | 29 |      | 7      | 54        |               |     |         |
| 집중시간 > 3 | D  | 5    | 4    | 9    | 6    | 38 | 45   | -7     | 49        | 49            | 0.4 | 39      |
|          | E  | 4    | 4    | 5    | 7    | 52 |      | 7      | 49        |               |     |         |

| 기준       | 구분 | 공부시간 | 집중시간 | 운동시간 | 알바시간 | 성적 | 성적평균 | 오차 (E) | 제곱오차 (SE) | 평균 제곱오차 (MSE) | 비율  | MSE 가중합 |
|----------|----|------|------|------|------|----|------|--------|-----------|---------------|-----|---------|
| 공부시간 ≤ 4 | B  | 2    | 1    | 8    | 9    | 21 | 25   | -4     | 16        | 16            | 0.6 | 9.6     |
|          | C  | 3    | 2    | 1    | 10   | 29 |      | 4      | 16        |               |     |         |
| 공부시간 > 4 | A  | 5    | 1    | 10   | 8    | 15 | 15   | 0      | 0         | 0             | 0.3 | 9.6     |

# 최적의 분할 기준 선정

| 구분  | 공부 시간 | 집중 시간 | 운동 시간 | 알바 시간 | 성적 |
|-----|-------|-------|-------|-------|----|
| A   | 5     | 1     | 10    | 8     | 15 |
| B   | 2     | 1     | 8     | 9     | 21 |
| C   | 3     | 2     | 1     | 10    | 29 |
| D   | 5     | 4     | 9     | 6     | 38 |
| E   | 4     | 4     | 5     | 7     | 52 |
| F   | 5     | 4     | 6     | 4     | 63 |
| G   | 6     | 5     | 2     | 5     | 70 |
| H   | 9     | 7     | 4     | 1     | 78 |
| I   | 7     | 7     | 3     | 2     | 91 |
| J   | 9     | 8     | 3     | 3     | 95 |
| 예측용 | 7     | 6     | 2     | 9     | 29 |

| 공부시간 | 조건  | Weighted MSE | 집중시간 | 조건  | Weighted MSE | 운동시간 | 조건  | Weighted MSE | 알바시간 | 조건  | Weighted MSE |
|------|-----|--------------|------|-----|--------------|------|-----|--------------|------|-----|--------------|
| 2    | 2.5 | 614.40       | 1    | 1.5 | 398.40       | 1    | 1.5 | 668.09       | 1    | 1.5 | 686.60       |
| 3    | 3.5 | 516.35       | 2    | 3   | 258.89       | 2    | 2.5 | 736.24       | 2    | 2.5 | 529.74       |
| 4    | 4.5 | 551.74       | 4    | 4.5 | 210.43       | 3    | 3.5 | 572.63       | 3    | 3.5 | 283.29       |
| 5    | 5.5 | 210.43       | 5    | 6   | 283.29       | 4    | 4.5 | 441.60       | 4    | 4.5 | 274.43       |
| 6    | 6.5 | 283.29       | 7    | 7.5 | 568.36       | 5    | 5.5 | 451.76       | 5    | 5.5 | 158.72       |
| 7    | 8   | 499.44       | 8    |     |              | 6    | 7   | 344.81       | 6    | 6.5 | 295.43       |
| 9    |     |              |      |     |              | 8    | 8.5 | 538.44       | 7    | 7.5 | 262.44       |
|      |     |              |      |     |              | 9    | 9.5 | 564.80       | 8    | 8.5 | 516.35       |
|      |     |              |      |     |              | 10   |     |              | 9    | 9.5 | 668.09       |
|      |     |              |      |     |              |      |     |              | 10   |     |              |



# Decision Tree Regression/Classification

## 회귀 Regression

### MSE(mean square error)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- $n$  : 샘플 개수
- $y_i$  : 실제 값 (target)
- $\hat{y}_i$  : 평균 값 (average)

### Information Gain (정보이득)

$$IG = MSE_{(before)} - \sum w_i MSE_{i(after)}$$

- 분할 전후 오차/불순도 감소량
- 값이 클수록 좋은 기준

## 분류 Classification

### Gini Impurity (지니 불순도)

$$Gini = 1 - \sum_i p_i^2$$

- $p_i$  : 클래스  $i$  의 비율

### Entropy (엔트로피)


$$Entropy = - \sum_i p_i \log p_i$$

- $p_i$  :  $i$  클래스의 비율
- 한 구간 안의 클래스 혼합 정도를 수치화
- 값  $\uparrow$  = 여러 클래스가 많이 섞임
- 0 = 한 클래스만 있음 (순수)

### 트리 분할 원리

- 기준 및 조건별 오차/불순도 계산
- 정보이득이 가장 큰 기준 선택

▼ 불순도 정도



| 성적 | 등급 |
|----|----|
| 15 | C  |
| 21 | C  |
| 29 | C  |
| 38 | C  |
| 52 | B  |
| 63 | B  |
| 70 | B  |
| 78 | B  |
| 91 | A  |
| 95 | A  |



# Random Forest : Decision Tree의 무작위 조합

단일 결정나무 → 학습 데이터에 민감, 과적합 발생 위험



## 랜덤 포레스트의 아이디어

- 무작위(Random)를 도입해 여러 트리를 학습
  - Bagging (Bootstrap Aggregating): 무작위로 추출된 데이터 샘플로 각 트리를 학습
  - Random Feature Selection: 분할 시 모든 특성을 쓰지 않고, 일부 특성만 무작위 선택
- 이렇게 만들어진 서로 다른 트리들을 결과를 결합(Ensemble)하여 해결

⇒ 안정적, 일반화 성능 향상

| 순서 | 이름 | 특성1   | 특성2   | 특성3   | 특성4 | 성적 |
|----|----|-------|-------|-------|-----|----|
| 1  | A  | 0.36  | 10.66 | -5.31 | 0   | 48 |
| 2  | B  | 0.81  | 12.90 | -4.72 | 1   | 94 |
| 3  | C  | 0.53  | 10.15 | -5.19 | 0   | 25 |
| 4  | D  | -0.18 | 11.01 | -4.58 | 0   | 75 |
| 5  | E  | -0.02 | 9.72  | -4.19 | 1   | 61 |

<원본 데이터>

| 순서 | 이름 | 특성1   | 특성2   | 특성4 | 성적 |
|----|----|-------|-------|-----|----|
| 1  | B  | 0.81  | 12.90 | 1   | 94 |
| 2  | E  | -0.02 | 9.72  | 1   | 61 |
| 3  | D  | -0.18 | 11.01 | 0   | 75 |
| 4  | B  | 0.81  | 12.90 | 1   | 94 |
| 5  | B  | 0.81  | 12.90 | 1   | 94 |


<RF Sample>

# Random Forest

**Bootstrap**  
**Random feature selection**

| 순서 | 이름 | 특성1   | 특성2   | 특성4 | 성적 |
|----|----|-------|-------|-----|----|
| 1  | B  | 0.81  | 12.90 | 1   | 94 |
| 2  | E  | -0.02 | 9.72  | 1   | 61 |
| 3  | D  | -0.18 | 11.01 | 0   | 75 |
| 4  | B  | 0.81  | 12.90 | 1   | 94 |
| 5  | B  | 0.81  | 12.90 | 1   | 94 |

<RF Sample 1>



**Aggregation**

| 순서 | 이름 | 특성1   | 특성2   | 특성3   | 특성4 | 성적 |
|----|----|-------|-------|-------|-----|----|
| 1  | A  | 0.36  | 10.66 | -5.31 | 0   | 48 |
| 2  | B  | 0.81  | 12.90 | -4.72 | 1   | 94 |
| 3  | C  | 0.53  | 10.15 | -5.19 | 0   | 25 |
| 4  | D  | -0.18 | 11.01 | -4.58 | 0   | 75 |
| 5  | E  | -0.02 | 9.72  | -4.19 | 1   | 61 |

<원본 데이터>


| 순서 | 이름 | 특성2   | 특성3   | 성적 |
|----|----|-------|-------|----|
| 1  | A  | 10.66 | -5.31 | 48 |
| 2  | D  | 11.01 | -4.58 | 75 |
| 3  | C  | 10.15 | -5.19 | 25 |
| 4  | D  | 11.01 | -4.58 | 75 |
| 5  | A  | 10.66 | -5.31 | 48 |

<RF Sample 2>

⋮

| 순서 | 이름 | 특성1   | 특성3   | 특성4 | 성적 |
|----|----|-------|-------|-----|----|
| 1  | C  | 0.53  | -5.19 | 0   | 25 |
| 2  | C  | 0.53  | -5.19 | 0   | 25 |
| 3  | E  | -0.02 | -4.19 | 1   | 61 |
| 4  | A  | 0.36  | -5.31 | 0   | 48 |
| 5  | E  | -0.02 | -4.19 | 1   | 61 |

<RF Sample n>




!

# Random Forest

**Bootstrap**  
**Random feature selection**

| 순서 | 이름 | 특성1   | 특성2   | 특성4 | 성적 |
|----|----|-------|-------|-----|----|
| 1  | B  | 0.81  | 12.90 | 1   | 94 |
| 2  | E  | -0.02 | 9.72  | 1   | 61 |
| 3  | D  | -0.18 | 11.01 | 0   | 75 |
| 4  | B  | 0.81  | 12.90 | 1   | 94 |
| 5  | B  | 0.81  | 12.90 | 1   | 94 |

<RF Sample 1>



→ 57  
(B)


**Aggregation**

| 순서 | 이름 | 특성1   | 특성2   | 특성3   | 특성4 | 성적 |
|----|----|-------|-------|-------|-----|----|
| 1  | A  | 0.36  | 10.66 | -5.31 | 0   | 48 |
| 2  | B  | 0.81  | 12.90 | -4.72 | 1   | 94 |
| 3  | C  | 0.53  | 10.15 | -5.19 | 0   | 25 |
| 4  | D  | -0.18 | 11.01 | -4.58 | 0   | 75 |
| 5  | E  | -0.02 | 9.72  | -4.19 | 1   | 61 |

<원본 데이터>

| 순서 | 이름 | 특성2   | 특성3   | 성적 |
|----|----|-------|-------|----|
| 1  | A  | 10.66 | -5.31 | 48 |
| 2  | D  | 11.01 | -4.58 | 75 |
| 3  | C  | 10.15 | -5.19 | 25 |
| 4  | D  | 11.01 | -4.58 | 75 |
| 5  | A  | 10.66 | -5.31 | 48 |

<RF Sample 2>



→ 53  
(B)

**51.7**  
(B)

회귀(분류)  
⇒ 평균(다수결)


⋮

| 이름 | 특성1  | 특성2   | 특성3   | 특성4 | 성적  |
|----|------|-------|-------|-----|-----|
| F  | 0.50 | 11.50 | -4.80 | 1   | ??? |

<예측 데이터>

| 순서 | 이름 | 특성1   | 특성3   | 특성4 | 성적 |
|----|----|-------|-------|-----|----|
| 1  | C  | 0.53  | -5.19 | 0   | 25 |
| 2  | C  | 0.53  | -5.19 | 0   | 25 |
| 3  | E  | -0.02 | -4.19 | 1   | 61 |
| 4  | A  | 0.36  | -5.31 | 0   | 48 |
| 5  | E  | -0.02 | -4.19 | 1   | 61 |

<RF Sample n>



→ 45  
(C)

# Random Forest 고려사항


Random Forest는 여러 부분에서 Random 특성이 존재하므로 고려할 사항이 있음

몇 개의 트리(=샘플 데이터셋의 수)를 사용할지? (n\_estimator)

- 보통 100~500 정도 고려
- 많다면 다양한 모델을 사용하고 안정성이 높아지지만 계산 비용이 증가


뽑아낼 특성의 수 (max\_features)

- 데이터셋을 구성할 때, 임의로 뽑아낼 특성의 최대 수
- 보통  $\sqrt{\text{특성수}}$  정도를 선택



트리 최대 깊이 (max\_depth)



- 하나의 트리가 가지를 뻗어갈 최대 길이
- 깊을 수록 성능이 좋지만 과적합 위험이 있음



# Feature Importance

각 입력특성(x1, x2, x3, ...)가 예측 성능 향상에 얼마나 기여했는지를 나타내는 지표  
분할 과정에서 예측 오차를 가장 크게 줄인 중요한 입력 특성(feature)

- 각 분할에서 정보 이득(Information Gain)을 계산
- 해당 feature가 사용된 모든 분할에서 감소량을 노드의 샘플 수 비율을 고려한 가중합으로 누적
- feature 별 기여도를 전체 합이 1이 되도록 정규화



$$IG = \Delta MSE = MSE_{(before)} - \sum w_i MSE_{i(after)}$$

$$contribution = \frac{N_{node}}{N_{total}} \times IG$$

$$x_1 = \sum contribution\ of\ x_1 = 1572 \Rightarrow 0.15$$

$$x_2 = \sum contribution\ of\ x_2 = 2315 \Rightarrow 0.23$$

$$x_3 = \sum contribution\ of\ x_3 = 1483 \Rightarrow 0.14$$

$$x_4 = \sum contribution\ of\ x_4 = 4827 \Rightarrow 0.48$$

| feature     | sample | beforeMSE | weightedMSE | InformationGain | sample ratio | contribution |
|-------------|--------|-----------|-------------|-----------------|--------------|--------------|
| 1 work      | 10     | 744       | 158.5       | 585.5           | 1.0          | 585.5        |
| 2 study     | 5      | 147       | 18          | 129             | 0.5          | 64.5         |
| 3 work      | 5      | 170       | 19.4        | 150.6           | 0.5          | 75.3         |
| 4 work      | 2      | 12        | 0           | 12              | 0.2          | 2.4          |
| 5 work      | 3      | 52        | 0.8         | 51.2            | 0.3          | 15.36        |
| 6 work      | 2      | 49        | 0           | 49              | 0.2          | 9.8          |
| 7 intensive | 3      | 32        | 1.8         | 30.2            | 0.3          | 9.06         |
| 8 intensive | 2      | 4         | 0           | 4               | 0.2          | 0.8          |
| 9 work      | 2      | 9         | 0           | 9               | 0.2          | 1.8          |

## Random Forest

랜덤포레스트

Bae Yeongrang

Color Material Application & AI Lab

Department of Textile Systems Engineering

Kyungpook National University