

Random Forest

랜덤포레스트

배영랑 박사과정

CMA&AI Lab

Color Material Application & AI Lab

Random Forest


랜덤 포레스트(Random Forest)는

의사결정나무(Decision Tree)를 무작위(Random)로 여러 개를 만들어 각각의 예측을 종합해 최종 결과를 내는 **앙상블(Ensemble)** 학습 방법.


Decision Tree(의사결정나무)는

데이터를 기준에 따라 분할해 예측을 수행하는 트리 구조의 알고리즘.

Decision Tree



Random Forest
Decision Tree Ensemble




Decision Tree

Decision Tree는


데이터를 잘 예측하기 위해, 데이터를 계속 나누는 알고리즘

구분	공부시간	집중시간	운동시간	알바시간	성적
A	5	1	10	8	15
B	2	1	8	9	21
C	3	2	1	10	29
D	5	4	9	6	38
E	4	4	5	7	52
F	5	4	6	4	63
G	6	5	2	5	70
H	9	7	4	1	78
I	7	7	3	2	91
J	9	8	3	3	95
예측용	7	6	2	9	???



⇒ 분할 전/후 상태 비교는 어떻게?

⇒ 어떤 기준이 좋은 기준일까?



데이터 상태와 분할

구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)
A	5	1	10	8	15	55	-40	1616	744
B	2	1	8	9	21		-34	1170	
C	3	2	1	10	29		-26	686	
D	5	4	9	6	38		-17	296	
E	4	4	5	7	52		-3	10	
F	5	4	6	4	63		8	61	
G	6	5	2	5	70		15	219	
H	9	7	4	1	78		23	520	
I	7	7	3	2	91		36	1282	
J	9	8	3	3	95		40	1584	

MSE = 744


예시:

- $y = [10, 11, 12] \rightarrow$ 예측 쉬움
- $y = [10, 50, 100] \rightarrow$ 데이터가 많이 퍼져 있어서 예측 어려움

데이터가 얼마나 예측하기 어려운 상태인지(흩어져 있는 정도)를 수치로 나타내 비교

데이터 상태와 분할

구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)
A	5	1	10	8	15	55	-40	1616	744
B	2	1	8	9	21		-34	1170	
C	3	2	1	10	29		-26	686	
D	5	4	9	6	38		-17	296	
E	4	4	5	7	52		-3	10	
F	5	4	6	4	63		8	61	
G	6	5	2	5	70		15	219	
H	9	7	4	1	78		23	520	
I	7	7	3	2	91		36	1282	
J	9	8	3	3	95		40	1584	



기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
알바시간 <=5.5	F	5	4	6	4	63	79	-16	269	147	0.5	159
	G	6	5	2	5	70		-9	88			
	H	9	7	4	1	78		-1	2			
	I	7	7	3	2	91		12	135			
	J	9	8	3	3	95		16	243			
알바시간 >5.5	A	5	1	10	8	15	31	-16	256	170	0.5	
	B	2	1	8	9	21		-10	100			
	C	3	2	1	10	29		-2	4			
	D	5	4	9	6	38		7	49			
	E	4	4	5	7	52		21	441			

⇒ 분할 전 MSE > 분할 후 MSE

⇒ 오차(MSE) 감소

구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)
A	5	1	10	8	15	55	-40	1616	744
B	2	1	8	9	21		-34	1170	
C	3	2	1	10	29		-26	686	
D	5	4	9	6	38		-17	296	
E	4	4	5	7	52		-3	10	
F	5	4	6	4	63		8	61	
G	6	5	2	5	70		15	219	
H	9	7	4	1	78		23	520	
I	7	7	3	2	91		36	1282	
J	9	8	3	3	95		40	1584	


기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
알바시간 <= 5.5	F	5	4	6	4	63	79	-16	269	147	0.5	159
	G	6	5	2	5	70		-9	88			
	H	9	7	4	1	78		-1	2			
	I	7	7	3	2	91		12	135			
	J	9	8	3	3	95		16	243			
알바시간 > 5.5	A	5	1	10	8	15	31	-16	256	170	0.5	
	B	2	1	8	9	21		-10	100			
	C	3	2	1	10	29		-2	4			
	D	5	4	9	6	38		7	49			
	E	4	4	5	7	52		21	441			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
집중시간 <= 6	F	5	4	6	4	63	67	-4	12	12	0.4	36.5
	G	6	5	2	5	70		4	12			
집중시간 > 6	H	9	7	4	1	78	88	-10	100	53	0.6	
	I	7	7	3	2	91		3	9			
	J	9	8	3	3	95		7	49			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
운동시간 <=3.5	H	9	7	4	1	78	78	0	0	0	0.3	2.4
운동시간 <=3.5	I	7	7	3	2	91	93	-2	4	4	0.6	
	J	9	8	3	3	95		2	4			


기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합	
집중시간 <= 3	A	5	1	10	8	15	22	-7	44	33	0.6	39	
	B	2	1	8	9	21		-1	0				
	C	3	2	1	10	29		7	54				
집중시간 > 3	D	5	4	9	6	38	45	-7	49	49	0.4		
	E	4	4	5	7	52		7	49				

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
공부시간 <= 4	B	2	1	8	9	21	25	-4	16	16	0.6	9.6
	C	3	2	1	10	29		4	16			
공부시간 > 4	A	5	1	10	8	15	15	0	0	0	0.3	



구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)
A	5	1	10	8	15	55	-40	1616	744
B	2	1	8	9	21		-34	1170	
C	3	2	1	10	29		-26	686	
D	5	4	9	6	38		-17	296	
E	4	4	5	7	52		-3	10	
F	5	4	6	4	63		8	61	
G	6	5	2	5	70		15	219	
H	9	7	4	1	78		23	520	
I	7	7	3	2	91		36	1282	
J	9	8	3	3	95		40	1584	

구분	공부 시간	집중 시간	운동 시간	알바 시간	성적
예측용	7	6	2	9	45



기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
알바시간 ≤ 5.5	F	5	4	6	4	63	79	-16	269	147	0.5	159
	G	6	5	2	5	70		-9	88			
	H	9	7	4	1	78		-1	2			
	I	7	7	3	2	91		12	135			
	J	9	8	3	3	95		16	243			
알바시간 > 5.5	A	5	1	10	8	15	31	-16	256	170	0.5	159
	B	2	1	8	9	21		-10	100			
	C	3	2	1	10	29		-2	4			
	D	5	4	9	6	38		7	49			
	E	4	4	5	7	52		21	441			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
집중시간 ≤ 6	F	5	4	6	4	63	67	-4	12	12	0.4	36.5
	G	6	5	2	5	70		4	12			
집중시간 > 6	H	9	7	4	1	78	88	-10	100	53	0.6	36.5
	I	7	7	3	2	91		3	9			
	J	9	8	3	3	95		7	49			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
운동시간 ≤ 3.5	H	9	7	4	1	78	78	0	0	0	0.3	2.4
	I	7	7	3	2	91		-2	4			
운동시간 ≤ 3.5	J	9	8	3	3	95	93	2	4	4	0.6	2.4


기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
집중시간 ≤ 3	A	5	1	10	8	15	22	-7	44	33	0.6	39
	B	2	1	8	9	21		-1	0			
	C	3	2	1	10	29		7	54			
집중시간 > 3	D	5	4	9	6	38	45	-7	49	49	0.4	39
	E	4	4	5	7	52		7	49			

기준	구분	공부시간	집중시간	운동시간	알바시간	성적	성적평균	오차 (E)	제곱오차 (SE)	평균 제곱오차 (MSE)	비율	MSE 가중합
공부시간 ≤ 4	B	2	1	8	9	21	25	-4	16	16	0.6	9.6
	C	3	2	1	10	29		4	16			
공부시간 > 4	A	5	1	10	8	15	15	0	0	0	0.3	9.6

최적의 분할 기준 선정

구분	공부 시간	집중 시간	운동 시간	알바 시간	성적
A	5	1	10	8	15
B	2	1	8	9	21
C	3	2	1	10	29
D	5	4	9	6	38
E	4	4	5	7	52
F	5	4	6	4	63
G	6	5	2	5	70
H	9	7	4	1	78
I	7	7	3	2	91
J	9	8	3	3	95
예측용	7	6	2	9	29

공부시간	조건	Weighted MSE	집중시간	조건	Weighted MSE	운동시간	조건	Weighted MSE	알바시간	조건	Weighted MSE
2	2.5	614.40	1	1.5	398.40	1	1.5	668.09	1	1.5	686.60
3	3.5	516.35	2	3	258.89	2	2.5	736.24	2	2.5	529.74
4	4.5	551.74	4	4.5	210.43	3	3.5	572.63	3	3.5	283.29
5	5.5	210.43	5	6	283.29	4	4.5	441.60	4	4.5	274.43
6	6.5	283.29	7	7.5	568.36	5	5.5	451.76	5	5.5	158.72
7	8	499.44	8			6	7	344.81	6	6.5	295.43
9						8	8.5	538.44	7	7.5	262.44
						9	9.5	564.80	8	8.5	516.35
						10			9	9.5	668.09
									10		



Decision Tree Regression/Classification

회귀 Regression

MSE(mean square error)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- n : 샘플 개수
- y_i : 실제 값 (target)
- $\hat{y}_i$: 평균 값 (average)

Information Gain (정보이득)

$$IG = MSE_{(before)} - \sum w_i MSE_{i(after)}$$

- 분할 전후 오차/불순도 감소량
- 값이 클수록 좋은 기준

분류 Classification

Gini Impurity (지니 불순도)

$$Gini = 1 - \sum_i p_i^2$$

- p_i : 클래스 i 의 비율

Entropy (엔트로피)

$$Entropy = - \sum_i p_i \log p_i$$

- p_i : i 클래스의 비율
- 한 구간 안의 클래스 혼합 정도를 수치화
- 값 $\uparrow$ = 여러 클래스가 많이 섞임
- 0 = 한 클래스만 있음 (순수)

트리 분할 원리

- 기준 및 조건별 오차/불순도 계산
- 정보이득이 가장 큰 기준 선택

성적	등급
15	C
21	C
29	C
38	C
52	B
63	B
70	B
78	B
91	A
95	A

Random Forest : Decision Tree의 무작위 조합

단일 결정나무 → 학습 데이터에 민감, 과적합 발생 위험

랜덤 포레스트의 아이디어

- 무작위(Random)를 도입해 여러 트리를 학습
 - Bagging (Bootstrap Aggregating): 무작위로 추출된 데이터 샘플로 각 트리를 학습
 - Random Feature Selection: 분할 시 모든 특성을 쓰지 않고, 일부 특성만 무작위 선택
- 이렇게 만들어진 서로 다른 트리들을 결과를 결합(Ensemble)하여 해결



⇒ 안정적, 일반화 성능 향상

순서	이름	특성1	특성2	특성3	특성4	성적
1	A	0.36	10.66	-5.31	0	48
2	B	0.81	12.90	-4.72	1	94
3	C	0.53	10.15	-5.19	0	25
4	D	-0.18	11.01	-4.58	0	75
5	E	-0.02	9.72	-4.19	1	61

<원본 데이터>

순서	이름	특성1	특성2	특성4	성적
1	B	0.81	12.90	1	94
2	E	-0.02	9.72	1	61
3	D	-0.18	11.01	0	75
4	B	0.81	12.90	1	94
5	B	0.81	12.90	1	94


<RF Sample>

Random Forest

Bootstrap
Random feature selection

순서	이름	특성1	특성2	특성4	성적
1	B	0.81	12.90	1	94
2	E	-0.02	9.72	1	61
3	D	-0.18	11.01	0	75
4	B	0.81	12.90	1	94
5	B	0.81	12.90	1	94

<RF Sample 1>



Aggregation

순서	이름	특성1	특성2	특성3	특성4	성적
1	A	0.36	10.66	-5.31	0	48
2	B	0.81	12.90	-4.72	1	94
3	C	0.53	10.15	-5.19	0	25
4	D	-0.18	11.01	-4.58	0	75
5	E	-0.02	9.72	-4.19	1	61

<원본 데이터>


순서	이름	특성2	특성3	성적
1	A	10.66	-5.31	48
2	D	11.01	-4.58	75
3	C	10.15	-5.19	25
4	D	11.01	-4.58	75
5	A	10.66	-5.31	48

<RF Sample 2>

⋮

순서	이름	특성1	특성3	특성4	성적
1	C	0.53	-5.19	0	25
2	C	0.53	-5.19	0	25
3	E	-0.02	-4.19	1	61
4	A	0.36	-5.31	0	48
5	E	-0.02	-4.19	1	61

<RF Sample n>




!

Random Forest

Bootstrap
Random feature selection

순서	이름	특성1	특성2	특성4	성적
1	B	0.81	12.90	1	94
2	E	-0.02	9.72	1	61
3	D	-0.18	11.01	0	75
4	B	0.81	12.90	1	94
5	B	0.81	12.90	1	94

<RF Sample 1>



Aggregation


→ 57
(B)

순서	이름	특성1	특성2	특성3	특성4	성적
1	A	0.36	10.66	-5.31	0	48
2	B	0.81	12.90	-4.72	1	94
3	C	0.53	10.15	-5.19	0	25
4	D	-0.18	11.01	-4.58	0	75
5	E	-0.02	9.72	-4.19	1	61

<원본 데이터>

순서	이름	특성2	특성3	성적
1	A	10.66	-5.31	48
2	D	11.01	-4.58	75
3	C	10.15	-5.19	25
4	D	11.01	-4.58	75
5	A	10.66	-5.31	48

<RF Sample 2>



→ 53
(B)

51.7
(B)

회귀(분류)
⇒ 평균(다수결)


⋮

이름	특성1	특성2	특성3	특성4	성적
F	0.50	11.50	-4.80	1	???

<예측 데이터>

순서	이름	특성1	특성3	특성4	성적
1	C	0.53	-5.19	0	25
2	C	0.53	-5.19	0	25
3	E	-0.02	-4.19	1	61
4	A	0.36	-5.31	0	48
5	E	-0.02	-4.19	1	61

<RF Sample n>



→ 45
(C)

Random Forest 고려사항


Random Forest는 여러 부분에서 Random 특성이 존재하므로 고려할 사항이 있음

몇 개의 트리(=샘플 데이터셋의 수)를 사용할지? (n_estimator)

- 보통 100~500 정도 고려
- 많다면 다양한 모델을 사용하고 안정성이 높아지지만 계산 비용이 증가


뽑아낼 특성의 수 (max_features)

- 데이터셋을 구성할 때, 임의로 뽑아낼 특성의 최대 수
- 보통 $\sqrt{(\text{특성수})}$ 정도를 선택



트리 최대 깊이 (max_depth)



- 하나의 트리가 가지를 뻗어갈 최대 길이
- 깊을 수록 성능이 좋지만 과적합 위험이 있음



Feature Importance

각 입력특성(x1, x2, x3, ...)가 예측 성능 향상에 얼마나 기여했는지를 나타내는 지표
분할 과정에서 예측 오차를 가장 크게 줄인 중요한 입력 특성(feature)

- 각 분할에서 정보 이득(Information Gain)을 계산
- 해당 feature가 사용된 모든 분할에서 감소량을 노드의 샘플 수 비율을 고려한 가중합으로 누적
- feature 별 기여도를 전체 합이 1이 되도록 정규화



$$IG = \Delta MSE = MSE_{(before)} - \sum w_i MSE_{i(after)}$$

$$contribution = \frac{N_{node}}{N_{total}} \times IG$$

$$x_1 = \sum contribution\ of\ x_1 = 1572 \Rightarrow 0.15$$

$$x_2 = \sum contribution\ of\ x_2 = 2315 \Rightarrow 0.23$$

$$x_3 = \sum contribution\ of\ x_3 = 1483 \Rightarrow 0.14$$

$$x_4 = \sum contribution\ of\ x_4 = 4827 \Rightarrow 0.48$$

feature	sample	beforeMSE	weightedMSE	InformationGain	sample ratio	contribution
1 work	10	744	158.5	585.5	1.0	585.5
2 study	5	147	18	129	0.5	64.5
3 work	5	170	19.4	150.6	0.5	75.3
4 work	2	12	0	12	0.2	2.4
5 work	3	52	0.8	51.2	0.3	15.36
6 work	2	49	0	49	0.2	9.8
7 intensive	3	32	1.8	30.2	0.3	9.06
8 intensive	2	4	0	4	0.2	0.8
9 work	2	9	0	9	0.2	1.8

Random Forest

랜덤포레스트

Bae Yeongrang

Color Material Application & AI Lab

Department of Textile Systems Engineering

Kyungpook National University